Sharp Predict

Produit et présenté par :

Sacha LUANGRATH
Tom PIVETEAU
Quentin DANIEL
Hadrien CASSION
Alessio GINO NOCERA

SOMMAIRE

I. Introduction

II. Méthodologie

III. Présentation des modèles utilisés et des résultats obtenus

- Random Forest (RF)
- Régression logistique
- Régression linéaire
- Support Vector Classifier (SVC)

IV. Conclusion

INTRODUCTION

Objectif

- **Prédire la direction d'une action le jour suivant**
- **Question clé** : « En analysant les données d'aujourd'hui, le prix de l'action va-t-il monter ou descendre demain ? »
- **L'apprentissage du modèle :** chaque mouvement de prix journalier passé est transformé en une catégorie simple :
  - 1 (hausse) : si le prix a augmenté de + de 0,5 %
  - 0 (neutre) : si variation faible du prix
  - -1 (baisse) : si le prix a baissé de + de 0,5 %
- **La sortie du modèle (prédiction) :** en fonction des données du jour :
  - Le modèle estime le mouvement futur attendu de l'action
  - Selon cette estimation, on prend une position (acheter, vendre ou rester neutre)

Données utilisées

Périmètre
138 des actions les plus liquides au monde + l'indice de volatilité VIX.

Historique
Données de cotation journalières de 2005 à 2025 (source : Yahoo finance)

Qualité des données
Toutes les actions sont en USD et aucune valeur manquante après nettoyage

MÉTHODOLOGIE

On transforme les données de cotation standards en 178 indicateurs (momentum, volatilité, tendance, risque) afin de fournir au modèle un maximum d'informations pour prédire la direction du marché

1

Variables brutes

Prix journaliers standards:

- Open
- High
- Low
- Close

VIX ajusté en volatilité journalière

Feature Engineering

1. Oscillateurs
Stochastic, William %R

2. Prix relatifs & Rendement
Mid, Close-to-High/Low, Rendement en close-to-close

3. Tendances
Moyennes Mobiles (courte et longue), Croissance anualisée

4. Volatilité
Plusieurs fênetres glissantes, Correlation avec le VIX

Résultat

178

Variables explicatives

(70 retenues après sélection)

2

Méthode d'entrainement : Times Series Split

- Apprendre : modèle entraîné sur 6 mois de données
- Vérifier : tester les prédictions sur les 6 mois suivants
- Répéter : faire glisser la fenêtre par période de 6 mois, de 2005 à 2025

Random Forest (RF)

Méthodologie Random Forest

Le **Random Forest** est un algorithme qui construit une multitude **d'arbres de décision** décorrélés sur des sous-échantillons de données, et dont la prédiction finale résulte d'un **vote majoritaire** visant à réduire la variance et le risque de sur-apprentissage.

Résultats

Le modèle démontre une excellente robustesse, attestée par la forte corrélation entre les jeux d'entraînement et de test (absence totale de sur-apprentissage). Cependant, la performance négative sur les deux périodes indique un **sous-apprentissage (underfitting)** : les variables actuelles ne permettent pas au Random Forest de capter les signaux haussiers du marché. Le modèle est stable, mais n'a pas encore trouvé de pouvoir prédictif.

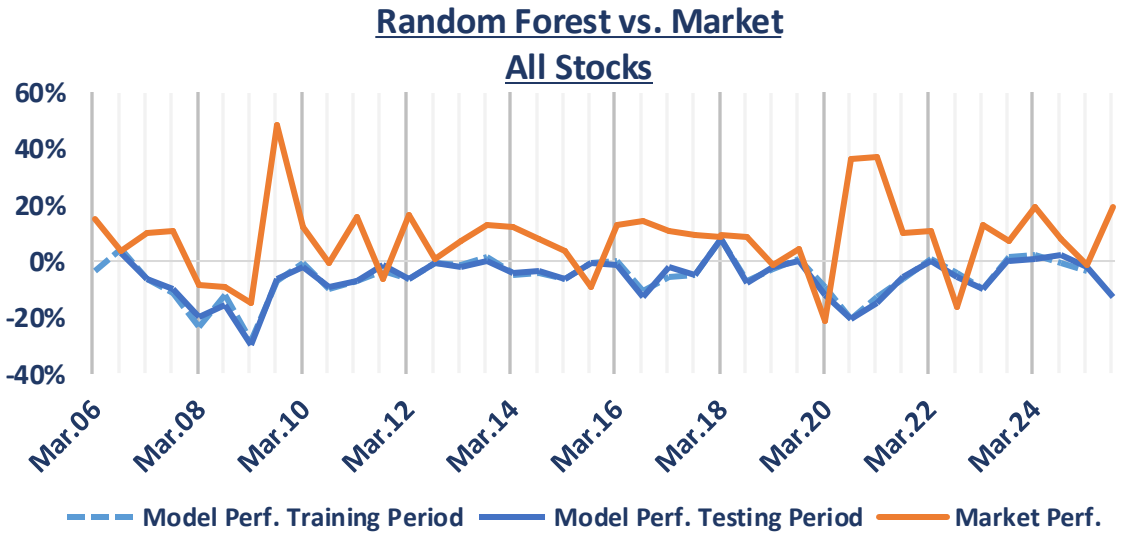

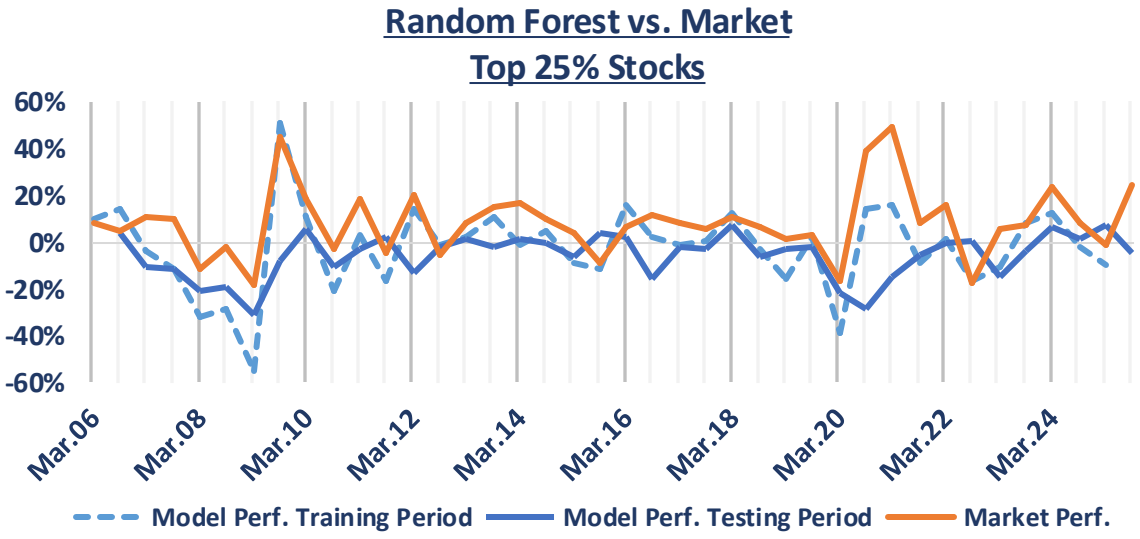

Régression logistique

Méthodologie régression logistique:

La **régression logistique** cherche à transformer une relation linéaire entre les features et les cours boursiers en **une classification binaire** (hausse/baisse) afin de prédire son évolution.

Résultats:

Le modèle **sous performe** le marché, la **binarité** de la classification **n'est pas appropriée** à la réalité d'un marché.

Interprétation:

- **Perte de nuance** : La classification binaire ignore l'amplitude des mouvements (volatilité vs variation faible).
- **Réalité complexe** : Le marché ne se résume pas à une simple hausse ou baisse.
- **Mauvaise généralisation** : Visible par l'écart de performance "Train" vs "Test" sur le Top 25%.

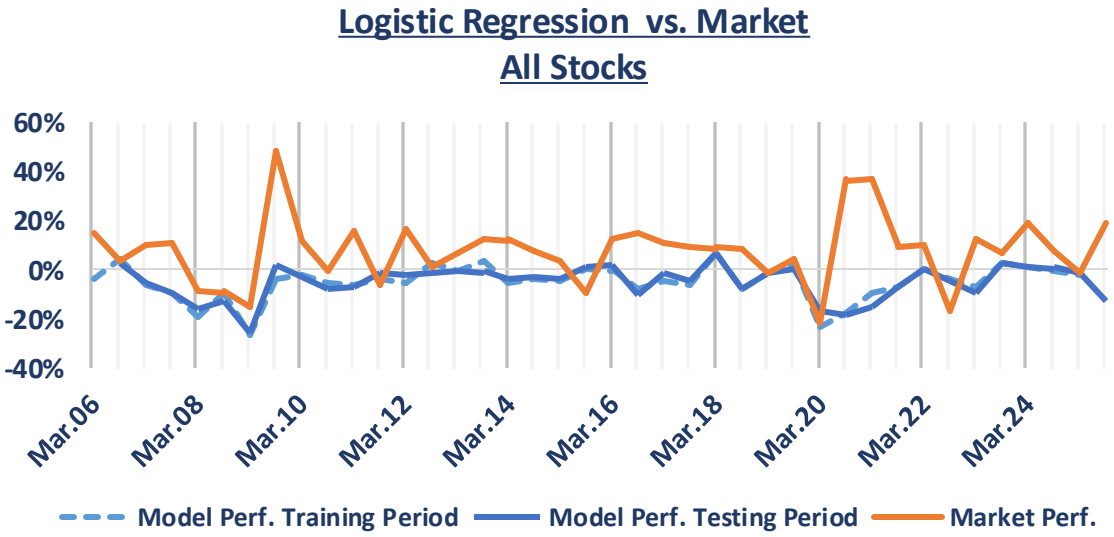

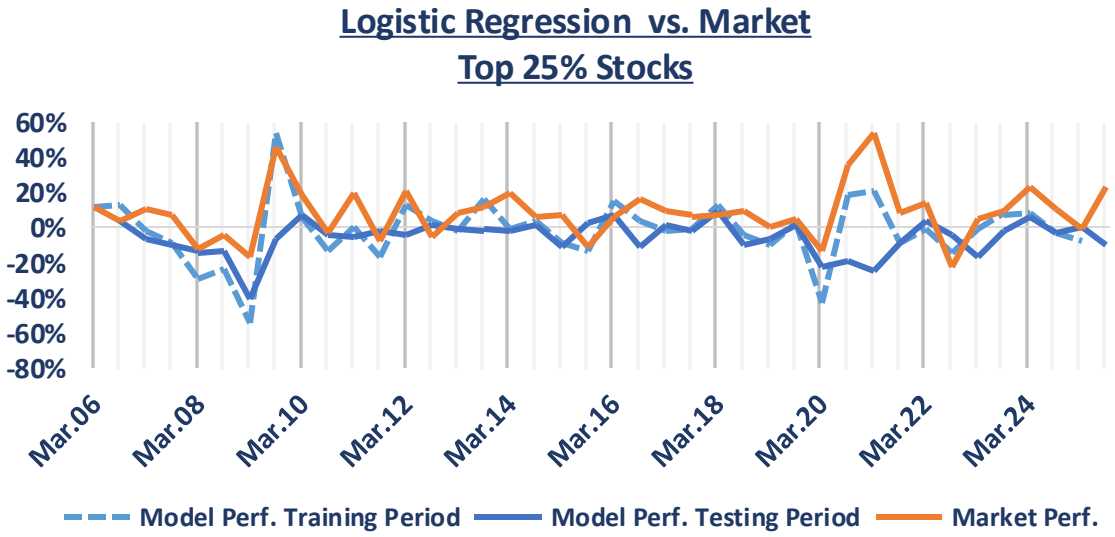

Régression linéaire

Méthodologie régression linéaire:

La **régression linéaire** cherche à trouver une **relation linéaire** entre **les features** et le **cours boursier** afin de prédire son évolution.

Résultats:

Le **modèle** est beaucoup **moins volatile** que le marché, ce qui se traduit en une **sous-performance** quand le marché est **haussier** et inversement quand il est **baissier**.

Interprétation:

- **Efficience des marchés** : Les résultats valident la difficulté de battre le marché (l'information étant déjà intégrée dans les prix).
- **Sur-apprentissage (Overfitting)**: Ecart de performance important entre le Training et le Testing. Le modèle apprend « par cœur » le passé.

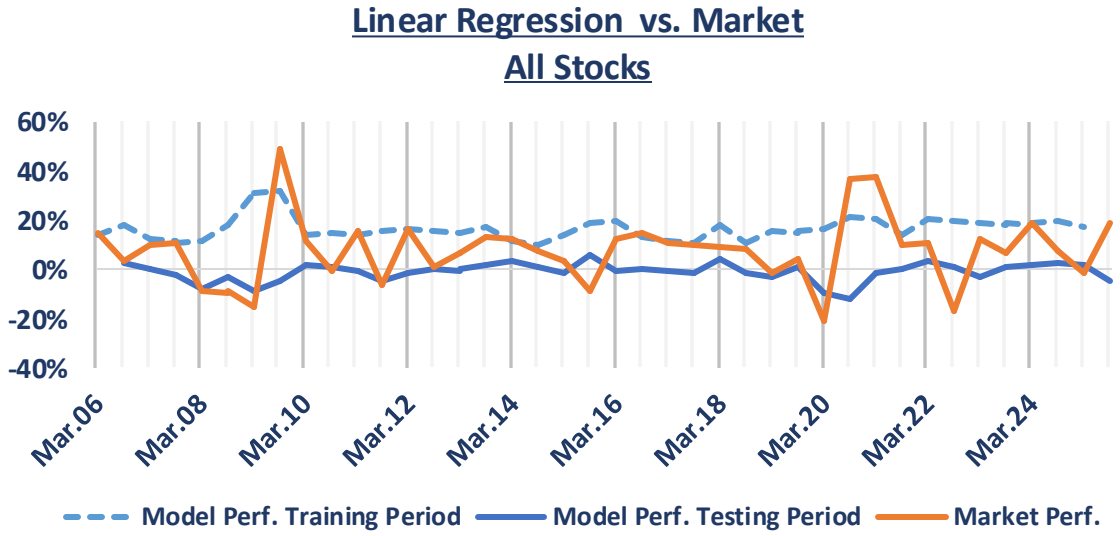

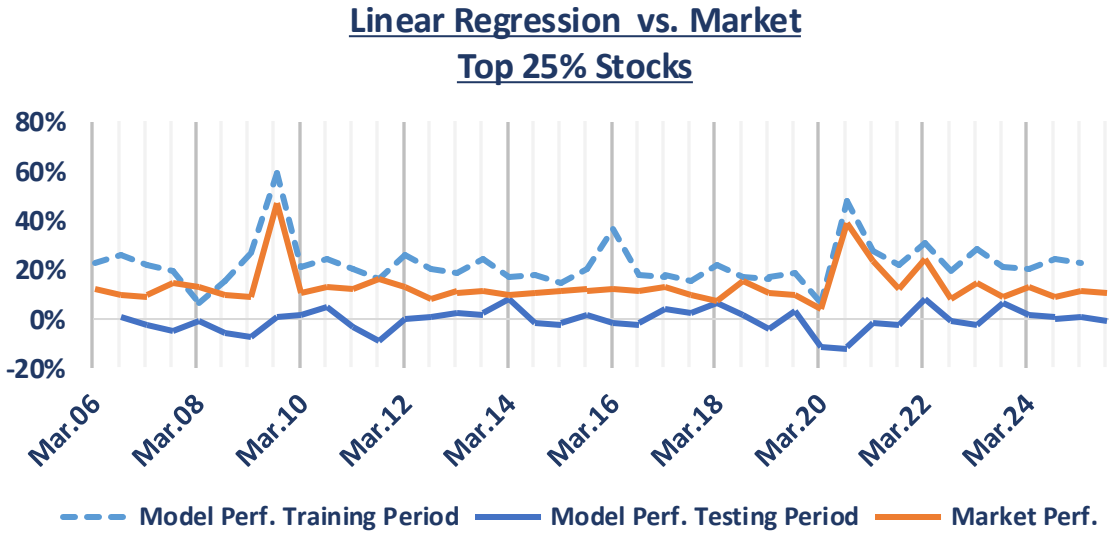

Support Vector Classifier (SVC)

Méthodologie SVC

Le **Support Vector Classifier** (SVC), membre de la famille des **SVM,** est un **classifieur** qui sépare les observations au moyen d'un **hyperplan** défini par des vecteurs de support.

Résultats

Le modèle affiche de meilleures performances en période de crise, en partie grâce à une exposition au marché réduite ; ses rendements restent toutefois globalement centrés autour de 0%.

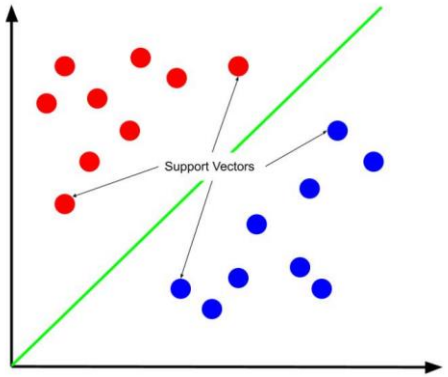

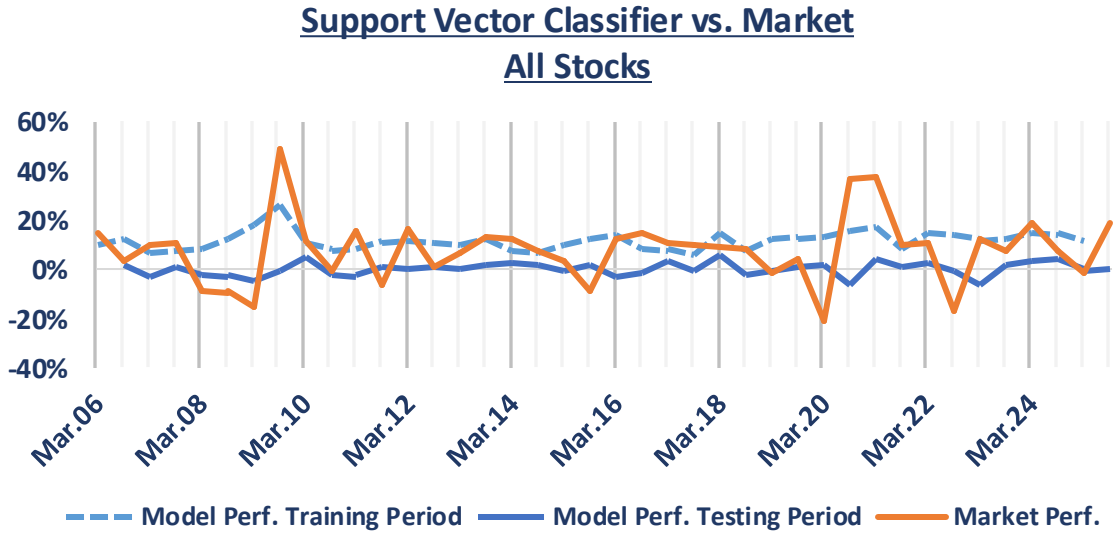

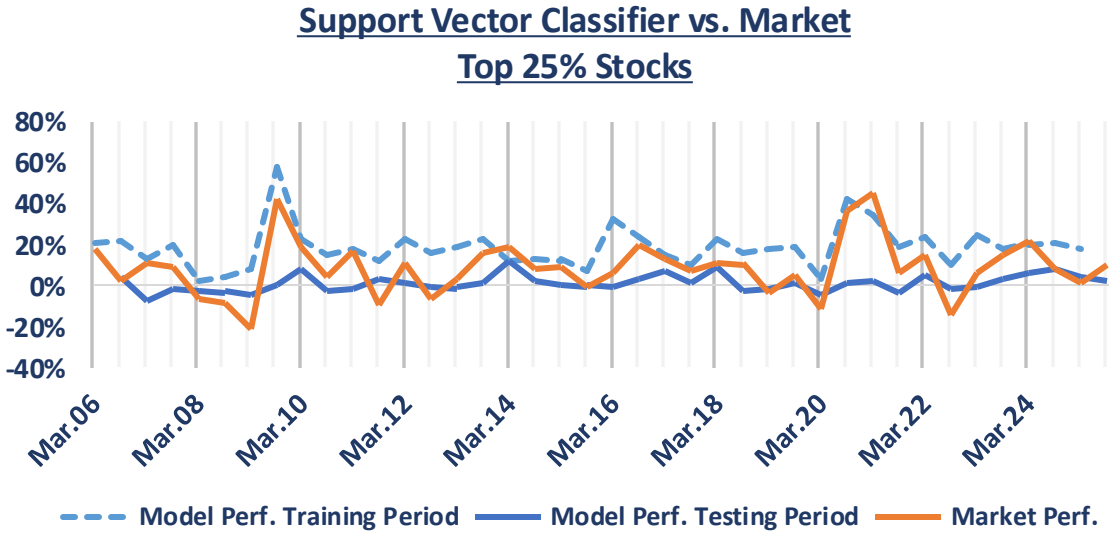

Conclusion

Résultats

Modèle	Rendement cumulé durant 20 ans
SVC	+ 71.72%
Régression linéaire	- 18.55%
Régression logistique	-87.62%
Random Forest	-89.44%

Parmi tous les modèles testés, seul le **SVC** parvient à anticiper correctement l'évolution future des 138 actions sélectionnées. Selon notre méthodologie, un investissement de **1$ en 2005 aurait atteint 1,71$ en 2025**.

Limites

- **Biais de sélection et biais du survivant** : univers restreint (138 actions) et potentiellement biaisé vers les titres encore cotés, ce qui ne reflète pas fidèlement l'ensemble du marché.
- **Variables simplistes** : utilisation exclusive de données brutes (Open/High/Low/Close/VIX), limitant la richesse informative du modèle.
- **Overfitting** : optimisation des seuils sur les données d'entraînement → performances durant l'entrainement trop élevées et mauvaise généralisation durant la période de test .
- **Fenêtres temporelles fixes (6m/6m)** : horizon trop court pour capturer les cycles économiques, mais trop long pour réagir à des chocs rapides.
- **Frais non intégrés** : absence de coûts de transaction pouvant fortement réduire la performance réelle.

Bonus : Focus sur un segment des données

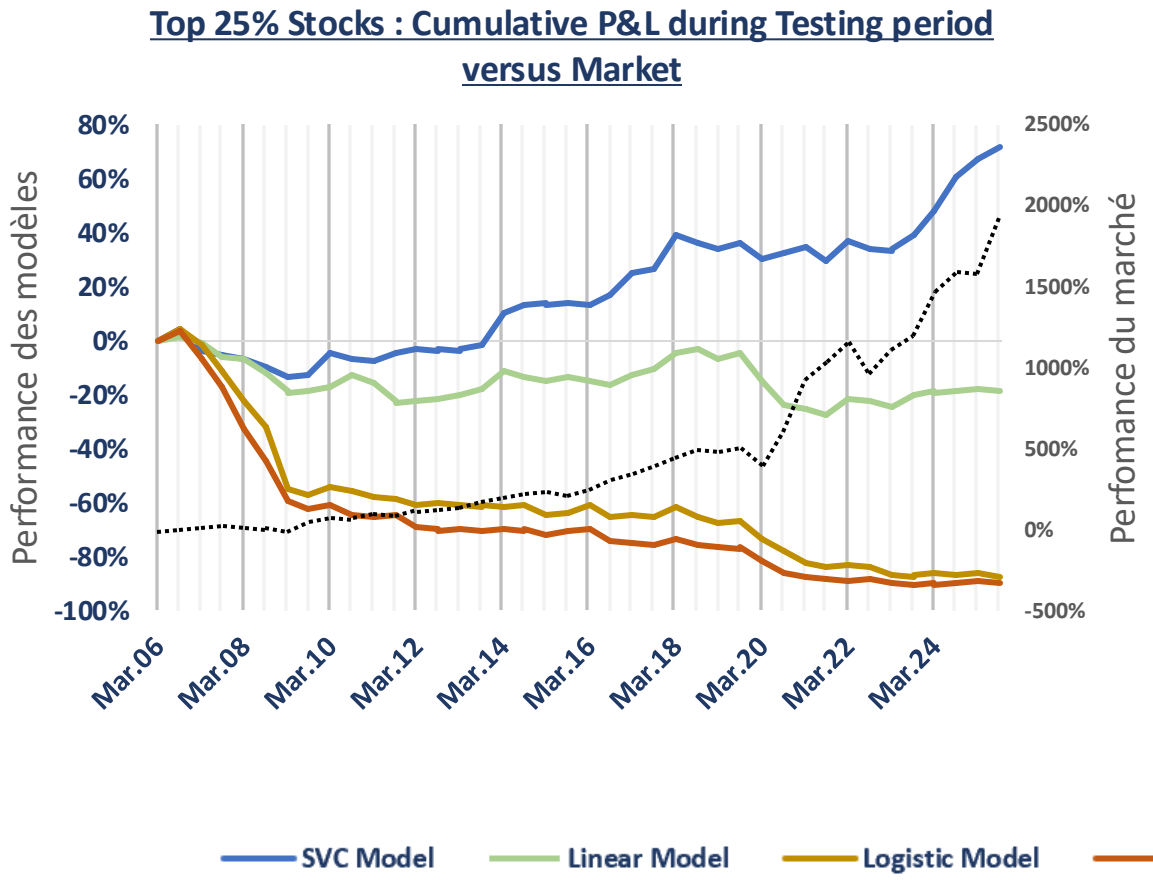

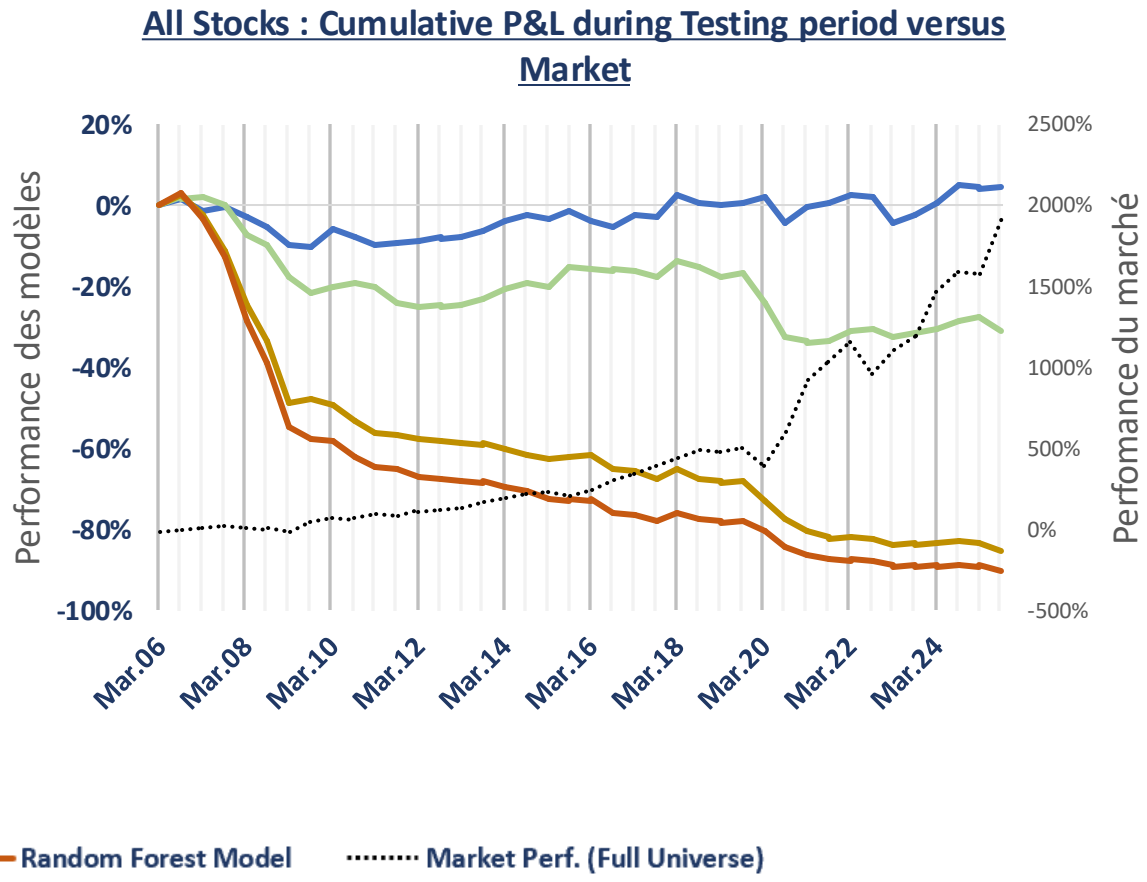

SVC Model — Linear Model — Logistic Model — Random Forest Model — Market Perf. (Full Universe)